赛题 04 企业智能信贷尽调 · 测试报告

状态：定稿（程柳供数，彭国补人工要点复核）。提交命名 `智算先锋队_赛题04_测试报告.md/.pdf`，A4、PDF≤30MB。
只引用 基线 `00e905f` 归档 `测试数据/评测/2026-10-25/00e905f/`，不混用 `2026-10-24/` 旧结果。

1. 环境与版本

项	记录
代码 SHA、分支	`00e905faeaf508021383e3a3fab58480d5aaec90`（短 `00e905f`），分支 `main`
数据包来源/哈希、样本数	官方公开包：`loan_application.csv` sha256 `5fe59629…671da`（10 笔）；`question_public.csv` `06064329…40aaea`（10 题）；答案仅评分侧 `公开测试集答案.csv` `04d58ae6…04d3991`
场景 ID、配置版本/哈希	`enterprise_dd`；`agents.yaml` / `scorecard.yaml` / `credit_model.yaml` 等见 `start-record.json` → `configVersions`
OS、Python、依赖版本	评测机 macOS；`ocft-backend/.venv` Python 3.x；依赖见 `requirements.txt` 冻结版
模型身份/API 标识与调用时间	`deepseek-v4.1-flash`，仅经 `app/llm.py`；申请批约 `2026-10-24T12:36Z` 起；不问询凭据
命令、原始结果与日志路径	`eval.dd04 prepare` → `eval.run --fresh` → `eval.dd04 export/validate`；产物目录见上；日志 `…/00e905f/logs/`

2. 公开申请逐条比对

标准列仅评分侧读取；Agent 运行时未注入答案。

申请编号	企业编号	系统风险评级	标准风险评级	评级一致	系统建议额度	标准建议额度	额度一致	评分要点覆盖	runId
LA001	E001	低风险	低风险	是	2500–3000	2500–3000	是	5/5	`run_61653ed11f87`
LA002	E002	中风险	中风险	是	1200–1500	1200–1500	是	5/5	`run_b7c5edb621ec`
LA003	E003	高风险	高风险	是	0	拒贷/极小额度	是	6/6	`run_3342b5eae017`
LA004	E004	中风险	中风险	是	1500–2000	1500–2000	是	5/5	`run_d61a54826392`
LA005	E005	低–中风险	低–中风险	是	600–800	600–800	是	5/5	`run_ffc68115348d`
LA006	E006	高风险	高风险	是	0	拒贷/极小额度	是	5/5	`run_4f436af5c45f`（补测，原 `run_a18a600faff3` 失败）
LA007	E007	低风险	低风险	是	400–500	400–500	是	5/5	`run_53b573e340bf`
LA008	E008	中风险	中风险	是	1000–1200	1000–1200	是	5/5	`run_82388e5646ab`（补测，原 `run_6627883fad5d` 失败）
LA009	E009	低风险	低风险	是	2000–2500	2000–2500	是	5/5	`run_41fa51a7732b`
LA010	E010	中风险	中风险	是	1500–2000	1500–2000	是	6/6	`run_18b0456a426f`

- 评级一致项数 / 总申请数：**10 / 10**（LA006、LA008 为补测结果，见下方「补测说明」）。
- 额度完全一致项数 / 总申请数：**10 / 10**（LA003、LA006 按拒贷语义 0 计）；数值区间精确 **8 / 8**。
- 结论与证据事实一致性：十笔六列结论与工具侧评级/额度对齐。
- 要点覆盖（人工复核，团队口径，非官方评分）：逐笔对照 `scoring_points` 阅读报告正文判定，合计 **52 / 52**；LA006 覆盖应收占营收 44.05%、经营现金流 350 万元远低于净利润 980 万元、未结被告 2 件 1,000 万元与被执行 280 万元、暂不准入；LA008 覆盖固定资产 4,500 万元与资产负债率 49.4%、全部涉诉 3 件 85 万元、建议额度 1000–1200 万元、抵押担保。覆盖只看要点是否被正确提及，不代表官方给分。
- 失败、空结果和未完成项保留在分母及错误清单中，不按成功子集虚增一致率。

补测说明（2026-10-25）：主批次（`00e905f`）中 LA006、LA008 因 `narrative_check_failed` 未出结论。两笔已在后续代码版本上经同一业务入口单独重跑（LA006 `run_4f436af5c45f`，10:29；LA008 `run_82388e5646ab`，10:31，模型 `deepseek-v4.1-flash`），结论取自同次 run 落库证据，并写入 `系统`

`输出/智算先锋队_赛题04_公开测评集结果.csv`。其余 8 笔仍为 `00e905f` 主批次结果，两部分并非同一代码版本、同一批次；耗时与 token 统计只描述主批次。最终冻结 SHA 上仍须整批重跑并以整批结果替换。

申请批：均 **27.14 s/笔**，P95 **34.25 s**，token **369,791**；`answersWithoutEvidence` = 0。

3. 不一致与异常归因

申请/问题编号	错误类型	系统实际行为	证据/日志	归属负责人	修复版本	复测结果
LA006 / LA008	`narrative_check_failed`	主批次中模型正文写入工具结果中不存在的百分比/金额，事实校验拦截	`applications/results.jsonl`、`official-export/*-status.csv`	王小文/黎锦涛（A2）	后续版本	已补测：LA006 needs_confirm LA008 succee 评级与额度均与 致
LA003（主测）	needs_confirmation	高风险否决项触发确认门禁，仍产出评级/额度 0	同上	产品口径	—	与参考「高风险 一致
LA003 / LA006（A3）	一致性不稳	双跑同失败码或 failed↔needs_confirmation	`consistency/一致性报告.md`	A2	待修	低/中风险一致 标；高风险不宣
LA003 / LA004 / LA005 / LA010	复核状态自相矛盾	「评级解释」写「无需人工复核」，同一报告「人工复核」节写「需业务人员确认 / 待业务人员复核」；评级与额度不受影响	`applications/results.jsonl` 报告正文	王小文（A2）	待修	未复测
Q003 / Q010	申请编号误引	E010 在库中对应 LA010 与 LA011 两笔申请，问询答复引用了 LA011；企业事实与数字正确	`questions/results.jsonl` 证据 `applicationIds`	胡乾豪（数据）/ 王小文	待修	未复测
Q005 / Q009 / LA003	舆情分口径	舆情健康分按事件重算为 0.0，与 `enterprise_risk.public_opinion_score`（45/48）并列出现，读者易误解	报告正文、`opinion.yaml`	王小文	待定（口径说明或改名）	—
Q002 / Q005 / Q010	要点遗漏	单项追问只调用对应角色工具，未汇总逾期、担保等跨维度事实	`questions/results.jsonl`	王小文（A2）	待修	未复测
参考答案自身	口径冲突	如 Q006 应收增长（数据显示应收同比低于营收）、Q005 涉诉金额 3200 万（数据合计 1850 万）	公开答案文件	评分侧披露	—	不迎合改系统

4. 自然语言问询

问题编号	企业编号	系统答复与 runId	覆盖判定（人工，团队口径）	事实复核与差异
Q001	E001	succeeded / `run_f120449f1323`	全覆盖	五章完整报告；低风险、2500–3000 万、反欺诈未命中、风控条件齐全
Q002	E003	succeeded / `run_9dfe3874b22e`	部分覆盖	75.0% 计算正确并判定偿债风险高；**未结合**逾期、涉诉 4 件、对外担保 1.2 亿、法人限高
Q003	E010	succeeded / `run_1fe570f458a3`	全覆盖	现金流 −800 万背离、其他应收 3500 万、应收偏高、关联 6 家均识别；答复把申请编号写成 LA011（库中 E010 另有一笔非公开集申请，见 §3）

问题编号	企业编号	系统答复与 runId	覆盖判定（人工，团队口径）	事实复核与差异
Q004	E009	succeeded / `run_81ce42d54f37`	全覆盖	区间 2000–2500 万含参考 2500 万；60 个月、利率下浮一致
Q005	E006	succeeded / `run_7af8f61977bb`	部分覆盖	涉诉 5 件、被执行、三条负面舆情均识别；**未提**逾期 1 次 180 万、对外担保 3000 万；舆情健康分 0.0 与数据表 48 分口径不同（见 §3）；涉诉金额 5 件合计 1850 万，参考答案写 3200 万
Q006	E002	succeeded / `run_62cfd209284a`	全覆盖	营收/净利三年数据与 46.7% CAGR 一致；参考称「应收增速快于营收」，按数据 2023 应收同比 41.7% < 营收 44.5%，系统写「基本同步」符合数据
Q007	E007	succeeded / `run_8505b3103269`	全覆盖	完整报告：低风险、400–500 万、24 个月、建议准入
Q008	E004	succeeded / `run_438f3edaf844`	基本覆盖	应收 11.18 次、存货 29.69 次、总资产 5.28 次、净利率 1.9% 一致；未明确写「符合贸易行业特征」
Q009	E003	succeeded / `run_788b14530ef2`	基本覆盖	4 条舆情事件与影响等级全部识别；综合分 0.0 与参考 45 分口径不同（见 §3）
Q010	E010	succeeded / `run_ddfb811d1c8b`	部分覆盖	关联 6 家、担保圈 2 家识别；**未给**关联企业构成（母/子/同一控制/联营）与对外担保 2 笔合计 2500 万；同样误写 LA011

合计：全覆盖 6、基本覆盖 2、部分覆盖 3（Q002/Q005/Q010），无失败。

问询：**10 / 10 succeeded**；均约 **14.12 s**，P95 **23.55 s**，token **157,814**。自动跑通 ≠ 要点满分；上表覆盖判定为团队人工口径，不代表官方给分。

5. 非公开集运行与耗时

> 官方非公开测评集（`06_非公开测试集_现场加试`，LA011–LA030 / E011–E030，**仅输入、无答案**），2026-10-25 实时重算。代码对应 `e87748b`（后端与正式批次运行代码逐行一致），即 `6e97cb3` + 一行通用 CAGR 修复（见下）。无标准答案，不给一致率。

总申请数	succeeded	待确认	失败	出具评级+额度	跑题墙钟	平均单笔	P50	P95	最大单笔	超过 30 秒数	token
20	14	5（LA013/016/028/029/030，均高风险拒贷）	1（LA024，`narrative_check_failed`）	19 / 20	8 min 13 s（端到端约 8.6 min）	24.5 s	23.0 s	35.2 s	44.4 s	3	768,854

- 系统评级分布：低风险 5、低–中风险 2、中风险 7、高风险 5、未生成 1；无证据答案 0。
- 首轮（未修复）4 笔未年净利润为负的企业因 `_cagr` 返回复数导致财报角色崩溃、未出结论；修复后重跑均为高风险 / 0。其余 15 笔两轮评级与额度一致；LA024 首轮 succeeded、正式批次 failed，如实保留。
- 结果文件：`系统输出/智算先锋队_赛题04_非公开测评集结果.csv` 与 `-status.csv`（`validate` 通过）
- 逐笔明细、输入哈希与两轮对比：非公开测评报告

6. 工程与合规验证

检查项	方法	结果/证据
数据体检与原文件不变	`eval.dd04` 准备工具	见 赛题04准备验证；≠ 正式业务分
参考答案/expected 隔离	prepare 白名单；扰动答案不进 Agent	`inputs/*.jsonl` 无答案字段；红线扫描另跑
六列结果格式与完整性	`eval.dd04 validate`	公开 10 笔、演练 5 笔均 **passed**（`系统输出/`）
外送模型与导出脱敏	抽查 llm 审计 / 报告	正式抽查属 A7（黎锦涛）
相同企业重复运行一致性	A3 双跑	LA001/LA002 一致；高风险不稳定，见一致性报告
失败与证据不足不编结论	业务异常 + 叙事拦截	LA006/LA008/LA104 六列保留「未生成结论」
干净环境启动	最终包解压	属 A6（陈修活），本报告不代替

本轮准备工具验证见 验证记录。正式 PDF 定稿时保留「工具验证 / 真实模型评测」两类区别。